

Bài Thực hành số 3

Tên môn học: **Dữ liệu lớn** 

## I. Tóm tắt bài thực hành

## 1. Yêu cầu lý thuyết

Sinh viên đã được trang bị kiến thức:

- O Cấu trúc hệ thống phân tán và framework lập trình Apache Spark
- o Đối tượng RDD (Resilient Distributed Dataset) trong Apache Spark

...

### 2. Nội dung

# ❖ Ôn tập lại những kiến thức cần thiết

- O Thành thạo ngôn ngữ lập trình Python.
- O Xem lại cấu trúc hệ thống phân tán và framework lập trình Apache Spark từ những kiến thức được học trên lớp lý thuyết và thực hành.
- Xem lại kiến thức về đối tượng RDD (Resilient Distributed Dataset)
   trong Apache Spark đã được học trên lớp lý thuyết.

#### ❖ Lập trình Python với Apache Spark thông qua PySpark

Tham khảo tại đường dẫn: <a href="http://spark.apache.org/docs/latest/rdd-programming-guide.html">http://spark.apache.org/docs/latest/rdd-programming-guide.html</a>

## ❖ Sử dụng lệnh spark-submit để triển khai ứng dụng

Tham khảo tại đường dẫn:
 <a href="http://spark.apache.org/docs/latest/submitting-applications.html">http://spark.apache.org/docs/latest/submitting-applications.html</a>

# 3. Kết quả cần đạt

- ✓ Sinh viên cần nắm rõ phương pháp lập trình bằng ngôn ngữ Python trên framework Apache Spark thông qua việc thao tác với RDD sử dụng PySpark.
- ✓ Sinh viên biết được cách sử dụng lệnh spark-submit để triển khai ứng dụng dữ liệu lớn. Hiểu và có thể hiệu chỉnh được các tham số khi triển khai.

#### II. Yêu cầu bài làm sinh viên

Nội dung thực hành buổi 03 được thực hiện theo từng cá nhân. Sinh viên upload một tập tin **<MSSV>.zip** hoặc **<MSSV>.rar** nén bên trong là các tập tin sau

- o baitap01.py | ipynb
- o baitap02.py | ipynb

0 ...

Lưu ý: Bài nộp không theo đúng quy định này sẽ không được tính.

## III. Bài tập

Nguyễn Hồ Duy Tri Trang 1

Sau khi cài đặt xong Apache Spark ở buổi học trước, sinh viên cần khởi động hệ thống phân tán và thực hiện theo các hướng dẫn của giảng viên thực hành. Thực hiện viết chương trình sau:

- Bài tập 1: Tính **trung bình cộng, trung bình nhân** của một dãy **số thực**.
- Bài tập 2: Tính phương sai và độ lệch chuẩn của một dãy số thực.
- Bài tập 3: Tính **tổng** của một dãy **phân số** đọc từ **tập tin** (không sử dụng thư viện phân số có sẵn).

#### IV. Phu luc

1. Cài đặt Apache Spark để sử dụng PySpark trên Jupyter Notebook

Mở tập tin conf/spark-env. sh thêm vào các biến môi trường cho Apache Spark như sau:

PYSPARK\_PYTHON=python3

PYSPARK\_DRIVER\_PYTHON=jupyter

PYSPARK DRIVER PYTHON OPTS=notebook



